SETIT 2005



3rd International Conference: Sciences of Electronic, Technologies of Information and Telecommunications March 27-31, 2005 – TUNISIA



Détection et interprétation des Gestes de la Main

Nicolas Mollet*, Ryad Chellali**

* nicolas.mollet@irisa.fr ** ryad.chellali@emn.fr

Résumé: Nos travaux portent sur le suivi et l'interprétation des mouvements de la main avec une seule caméra fixe. Ils visent à fournir une interface homme-machine de faible- coût permettant de commander des systèmes via une simple WebCam. Bien que l'utilisation d'un tel matériel laisse supposer la limitation à un jeu de commandes minimum, i.e. un nombre limité de configurations de la main, nous montrons ici que ce jeu est suffisant pour réaliser des tâches complexes tel que le pilotage de robots. Dans ce papier, nous proposons un schéma de détection de la main de l'utilisateur et une méthode de recalage de cette dernière sur un modèle 3D articulé et ce en temps réel. Des résultats de tests réels ainsi que des commentaires relatifs à notre approche sont donnés.

Mots clés: Interaction homme-machine, télérobotique, analyse d'images, vision 3D.

1 Introduction

L'efficience des interfaces homme machine dépend grandement de la nature de l'information que l'homme transmet à la machine et du canal qu'il utilise pour ce faire. Par exemple, le canal peut être la voix et l'homme transmet des ordres vocaux. L'interface peut être le couple écran souris et l'homme transmet ses ordres en ciblant à l'aide de la souris la représentation graphique de l'action à exécuter. Ces interfaces et bien d'autres sont limitées : dans le premier cas l'utilisation de la commande vocale suppose un apprentissage vocal multi locuteurs des ordres. Dans le second, elle suppose l'utilisation d'un matériel $ad\ hoc$.

D'une manière générale, les interfaces disponibles sont destinées à des utilisateurs expérimentés (ou du moins familiarisés avec les nouvelles technologies) ou bien nécessite des infrastructures spécifiques qui rendent leur utilisation à grande échelle problématique.

Dans les années 90, les recherches se sont orientées alors vers la conception d'interfaces simples et souples. Le MIT a été précurseur dans ce domaine en introduisant le concept de l'interface transparente. Utilisée dans un contexte domestique (la maison intelligente), les chercheurs du MIT ont développé des systèmes capables de capturer des ordres gestuels et vocaux pour interagir avec les éléments d'une maison classique. Philips et Microsoft développent leurs projets dans une même optique. Ces travaux contrastent fortement avec les approches classiques. En effet, toute utilisation de système de mesure-

communication embarqué est bannie : les gants de donnés par exemple sont abandonnés malgré les efforts réalisés sur la diminution du poids de ces outils et l'augmentation du confort de leur port au niveau de la main.

Notre travail a porté sur la réalisation d'une interface d'entrée qui soit la plus transparente et la plus banalisée possible : en d'autres termes, notre effort a porté sur la manière de réduire les contraintes qui s'imposent généralement à l'utilisateur pour lui permettre de transmettre ses ordres au système distant. Nous avons évité toutes les solutions qui embarquent un appareil ou laissent l'opérateur lier à une base fixe par le biais d'un câble. Par ailleurs, notre effort a porté aussi sur les aspects cognitifs du lien opérateurmachine. Nous avons souhaité des échanges transparents : l'opérateur ne doit pas fournir des efforts mentaux ou physiques excessifs pour générer les ordres transmis à la machine.

La solution adoptée a consisté à considérer la main comme le canal source des informations transmises à l'opérateur et la gestuelle réalisée par cet organe comme contenu (ordres). Partant de ces hypothèses de travail, nous avons réaliser un système basé sur l'analyse d'images capable de détecter la main, de la suivre, de déterminer ses configurations et les interprétés comme postures 3D. La détection de la main s'effectue par l'analyse temporelle des images acquises par une seule caméra fixe. Pour le suivi, nous mettons en concordance un modèle 3D poly-articulé de la main et son avatar 3D dans un monde virtuel. Cette information peut être utilisée sur un large spectre d'applications. L'information complète ou le modèle complet de la main étant de faible volume, les

transferts de ce modèle sont rapides et permettent par exemple de piloter une main robotisée distante via des réseaux à faibles débits. Une autre utilisation peut consister simplement à piloter des systèmes à deux états tel un interrupteur de lumière dans une maison « intelligente ». Dans un cadre tel que celui du dernier exemple, de nouvelles contraintes s'ajoutent à celles énoncées précédemment : il s'agit de contraintes économiques. En effet, pour être utilisable dans des environnements domestiques, l'interface doit être de faible coût. Ceci a en grande partie orienté nos choix technologiques et par conséquent les choix méthodologiques.

Ce papier présente notre solution faible coût, temps réel et transparente pour permettre à un utilisateur novice d'interagir avec des systèmes automatiques. Nous donnons en premier le schéma général de fonctionnement du système. Dans un deuxième temps, nous explicitons comment s'effectue la segmentation temps réel de l'image dans un environnement complexe, et son encodage. Nous fournissons ensuite un modèle 3D de la main. Dans la quatrième partie, nous présentons l'analyse de l'encodage de la main afin de calibrer le modèle 3D. Enfin, nous proposons dans la dernière partie notre approche pour le suivi des mouvements.

2 Un bref Etat de l'art

La notion d'interface homme-machine a été abordée il y a plusieurs décennies. Elle a concerné jusquà récemment les problèmes de la mise à disposition d'informations de type supervision pour le pilotage d'installations ou de systèmes complexes. Le transport aérien (avec les cockpits d'avions ou les centres d'aiguillage) ou la conduite d'usines de production (les centrales électriques ou les chaînes d'assemblage) ont largement bénéficié développements spécifiques de l'IHM avec pour objectifs de réduire la charge mentale et accélérer le temps de réaction du superviseur dans sa prise de décision dans la conduite d'un process. Avec le développement et la banalisation des calculateurs pour des applications domestiques, les efforts se sont portés sur la simplification des échanges entre un utilisateur "novice" et une machine plus versatile. Plusieurs aspects fondamentaux différencient l'IHM classique (ou plus exactement orientée métier) et l'interface qu'on retrouverait dans une maison :

- le contenu de l'information échangée
- l'équilibre entre l'information rentrante et celle sortante
- la mobilité de la cible, l'utilisateur en l'occurrence

Ci après, nous donnons une liste non exhaustive de quelques travaux permettant de balayer un spectre large de recherches. Les travaux à l'université de Boston [5] ont permis de créer un système nommé SMA capable de suivre et de reconstituer en temps réel les mouvements d'une main d'un individu filmé de plain-pied. La main destinée à commander est d'abord isolée, puis on teste en boucle si ce qu'on vient d'isoler (l'image actuelle de cette main) correspond à une posture apprise par un réseau de neurones. A chaque posture détectée correspond un passage de paramètres qui va permettre d'afficher un modèle 3D ayant la même posture.

Au sein du Groupe Interaction et Modalités, dans le département CHM de l'équipe du LIMSI à Evry, un système baptisé PoG [1] reconnaît différents types de gestes correspondant à des désignations de l'utilisateur. Il calcule ensuite la position de ou des objets désignés en analysant la position et l'orientation de l'index. Ce système est décomposé en 3 modules : extraction, reconnaissance et localisation. Le module d'extraction est en charge de délivrer des primitives visuelles importantes (vitesse, accélération, variations temporelles du déplacement des pixels). analysé vecteur est pour en déduire caractéristiques connues, correspondantes à des configurations reconnues. Enfin, la localisation réalise le calcul de ce qui a été pointé.

Dans le cadre du projet ARTEMIS à l'Institut National des Télécommunications, Ouhhad [2] présente un système de reconnaissance de gestes par recalage d'un modèle 3D. Il commence par estimer la distribution des couleurs « teinte-chair » [D2] dans l'image afin d'isoler la main. Puis une phase de reconnaissance adapte le modèle 3D à la main isolée en utilisant des moments d'inerties.

Au sein de France Telecom, Marcel et son équipe [3] ont implémenté une extension du projet LISTEN (système de suivi de personnes, développé à Lannion) pour reconnaître des postures de la main. Tout d'abord, la séquence d'entrée est filtrée en « teintechair » [2] afin de faire ressortir la main. Puis, on détecte parmi les zones en mouvement, celles qui ressemblent à une main, et on associe alors des entités de type *blobs* à ces zones. On tente alors de reconnaître des postures caractéristiques parmi un dictionnaire de *blobs*. Ces postures connues peuvent correspondre à des ordres par exemple.

Une approche originale a été testée par Freeman [4]. A partir de l'image d'une main sur un fond de couleur uniforme, il génère un diagramme des orientations globales de l'image, et teste si ce diagramme est proche d'un modèle connu ou non ; il détecte ainsi des postures particulières. Il précise bien qu'il faut un système pour isoler la main, car appliquer ce système à une image de vue d'ensemble n'est pas fiable, les orientations de la main ne faisant que faiblement varier les orientations globales.

Il ressort de ce bref constat la trame générale d'analyse suivante:

- Extraction de l'information voulue, donc ici la main,
- Reconnaissance de sa position/orientation,
- Modélisation 3D pour son suivi.

Les techniques d'extraction de la main utilisent souvent les notions de couleur et de mouvement. La teinte-chair ou couleur caractéristique de la peau est un paramètre discriminant dans une segmentation des images pour retrouver la main. Le mouvement permet quant à lui de différencier le fond qui est supposé dans une majorité de cas de l'opérateur qui lui et en mouvement (au moins sa main). En combinant les deux informations on arrive généralement à isoler la main. Dans un deuxième temps, la zone supposée représenter la main est d'abord confirmée comme étant une main. Une première hypothèse d'estimation de sa posture est émise. A partir de cette hypothèse, un suivi de certaines caractéristiques de la zone main est assuré pour mettre en concordance ces caractéristiques avec un modèle 3D de la main.

3 Fonctionnement général du système

Notre système obéit au schéma présenté plus haut. On commence par extraire la main dans le flux vidéo. Cette extraction se fait après une phase d'adaptation : la couleur de la peau étant propre à chaque individu, nous cherchons automatiquement les seuils sur les deux composantes R et G (respectivement rouge et verte) normalisées.

Cette recherche se base sur une double hypothèse :

- les deux composantes couleur appartiennent à des intervalles connus,
- la main est le seul objet mobile dans la scène au moins pendant la phase d'initialisation.

Une fois la zone main détectée, ses contours sont extraits et codés. Cette représentation est alors traitée pour en extraire un ensemble de points caractéristiques. Par comparaison à un modèle 3D synthétique de la main, on fait le recalage des deux entités (synthétique et réelle). Par un processus d'émission-vérification d'hypothèses, le modèle est actualisé et une modification de la main synthétique s'effectue en fonction des mesures issues du traitement du flux vidéo.

4 Extraction et encodage de la main

4.1 Segmentation combinée

Notre méthode de segmentation est composée de deux méthodes traditionnelles : la segmentation colorimétrique et la segmentation du mouvement.

La segmentation colorimétrique ou *teinte-chair* permet de repérer des éléments dont la couleur est la plus proche de celle de la peau. Les intervalles que nous avons retenues après de multiples tests sont [90,200] pour la composante R et [10,40] pour la composante G. Ces paramètres sont très sensibles aux conditions d'éclairage et à la présence d'éléments ayant des couleurs proches de la peau. Ces réglages ont été obtenus à partir d'une population moyenne de notre laboratoire et ils ne peuvent par conséquent être universels.

La combinaison des deux méthodes se fait comme suit. Tout d'abord, dans une phase d'initialisation, nous réalisons un cliché de l'environnement. Ensuite, pour chaque pixel dont la teinte change, nous testons s'il correspond à une teinte chair ou non. Nous faisons l'hypothèse ici que la main est le seul objet ayant une teinte contenue dans les intervalles de couleur qui bouge dans la scène pendant la phase d'initialisation.



Figure 1. segmentation teinte-chair seule sur un fond simple.

L'ajustement des intervalles se fait alors automatiquement en collaboration avec la détection du mouvement.

Cette segmentation combinée a fournit des résultats satisfaisants et exploitables, même sur des fonds complexes. Elle présente l'avantage d'être rapide et donc peu gourmande en ressources et en temps de calcul.

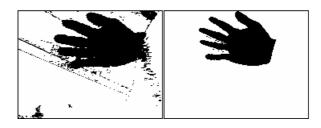


Figure 2. segmentation teinte-chair seule sur un fond complexe, puis segmentation combinée sur ce même fond.

La segmentation par le mouvement supplée la teinte-chair. L'image signée du fond est créé et est

mémorisée sous la forme d'une matrice ayant une structure particulière : entre les pixels voisins on établit des relations d'ordre au niveau de deux composantes couleur (« < » ou « > » par exemple). Tout nouvel objet qui apparait dans la scène brise localement cette structure. On détecte alors aisément une différence dans la scène, ce qui permet une isolation des nouveaux éléments. Le problème majeur de cette méthode est que l'image segmentée est fortement bruitée, car l'éclairage naturel offre beaucoup de variations sur les images vidéos.



Figure 3. Résultat de la segmentation combinée sur un fond complexe en temps-réel.

4.2 Codage de la main

Nous réalisons l'extraction de la main dans l'image par une méthode de segmentation combinée présentée dans le point 4.1. L'image obtenue nécessite une phase de codage afin d'en permettre l'analyse : nous avons codé le contour de la main grâce au codage de Freeman. L'analyse qui est ensuite faite a pour but d'extraire les points de courbure de ce contour, afin de reconnaître des points caractéristiques comme le bout des doigts. Une fois l'initialisation effectuée, nous réalisons une interpolation de chacun de ces points caractéristiques selon notre modèle de suivi, afin de limiter les zones de recherche et gagner en performances. Enfin, nous recalons le modèle prévu par rapport à la réalité, et passons alors les informations angulaires et spatiales au modèle 3D.

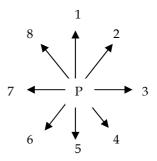
4.2.1 Codage de Freeman

Nous travaillons sur les contours de la main. Nous appliquons donc sur l'image précédemment segmentée un filtre gradient. Le contour obtenu est parcouru et encodé avec le codage de Freeman, qui traduit les orientations prises par la suite des vecteurs, chacun obtenu entre deux points successifs du contour. Ce codage brut est ensuite lissé afin de gommer les variations fines, pour ne retenir que les orientations globales du contour.

Figure 4. Codage de Freeman decrivant les vecteurs de parcours du contour segmenté.

4.2.1 Analyse des informations

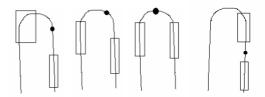
Sur ce contour codé et lissé, nous cherchons alors à extraire des points caractéristiques : les maxima de courbure. Ceux-ci sont aux sommets des zones que



constituent les points de courbure du contour. Nous recherchons 11 points : les bouts des doigts, les interstices situés entre eux, et les bords du poignet.

Figure 5. *Processus de détection d'une zone de courbure.*

L'idée de l'algorithme de recherche est la collaboration de deux fenêtres de visualisation sur ce codage. Une première fenêtre est centrée sur le point courant. Nous y calculons alors l'orientation globale



du contour, une moyenne des vecteurs représentés par le codage de Freeman. Une deuxième fenêtre est placée à une valeur donnée de points suivants sur le contour. Suivant le même principe, on y calcule l'orientation globale du contour. Si la différence entre les deux valeurs est nulle, le point de contour situé entre ces deux zones est situé sur une ligne. S'il vaut 1, nous considérons qu'il est sur une zone de courbure léger. S'il vaut 2 ou plus, il s'agira d'un point de courbure forte. Avec ce principe, nous isolons donc des zones, droites ou de courbure, et pour ces dernières nous en calculons le milieu qui correspond aux maxima de courbure.

Nous obtenons alors un repérage des 11 maxima de courbure que comprend le contour fermé de la main, ainsi que des lignes constituées par les bords des doigts, de la paume et du poignet.

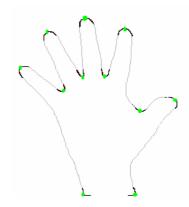


Figure 6. Détection des 11 points de courbure.

5 Modèle 3D

Nous proposons un modèle à 26° de libertés. Après analyse de différents travaux, ceux d'Hocine Ouhaddi [15] nous ont semblés le mieux traduire notre problème et nous faisons le même choix de modèle. Nous le retrouvons dans le schéma ci-dessous, et y rajoutons 3 degrés de libertés supplémentaires pour les mouvements de translation. Les postures prises par le modèle s'expriment par valeurs d'angles sur les différents degrés de libertés des articulations.

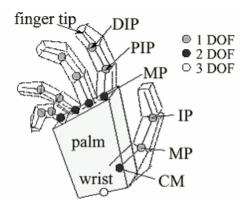


Figure 7. Modele 3D retenu.

6 Calibration du modele 3D sur la main

Le rôle principal de cette phase est d'adapter le modèle de suivi et le modèle 3D à l'utilisateur. Nous pouvons ainsi ajuster les longueurs des doigts, et cette position connue permet de caler avec certitude tous les éléments constituant les 2 modèles de la main (modèle 3D et modèle encodé).

6.1 Recherche des sommets

Nous recherchons tout d'abord à identifier les sommets des doigts. La position initiale impute que le

plus haut maxima de courbure corresponde au sommet du majeur. Nous recherchons ensuite des équivalences de distance entre deux maxima de courbure successifs, tel illustré dans la figure ci-dessus. Avec cette méthode, nous identifions aisément les 4 sommets des doigts de l'utilisateur, et les interstices entre les doigts.

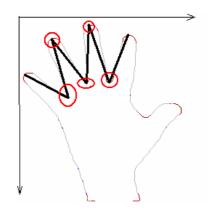


Figure 8. Extraction des sommets par recherche de 4 points particuliers équidistants successivement.

6.2 Recherche des bases des doigts

Nous cherchons à identifier une localisation plausible de la base des doigts. Pour l'annulaire et le majeur, ces points seront estimés au centre des interstices correspondants. Pour l'auriculaire, nous effectuons une symétrie centrale de la base de l'annulaire autour de l'interstice annulaire/auriculaire. Nous procédons de même pour l'index, mais corrigeons sa position avec l'interstice pouce/index, tout en gardant la précédente mesure de distance avec l'interstice majeur/index.

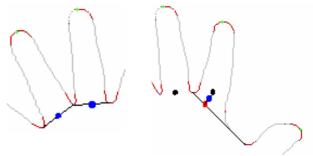


Figure 9. Détermination des bases des doigts, par centrage et réajustements, en utilisant les sommets particuliers trouves précédemment.

6.3 Recherche du « point de bord » de la main

Nous estimons au préalable un centre de la main, le point « 0 » dans la figure 9. Nous projetons ce point horizontalement, et obtenons le point de contour 1. De ce point sont lancées deux méthodes de suivi de lignes continues, qui fournissent les points 2 et 3. Du point 3 nous lançons une autre méthode de suivi de ligne continue, plus exigeante en linéarité, et obtenons le point 4. Des point 3 et 4, nous calculons le milieu sur le contour de la main, le point 5, qui sera appelé par la suite « point de bord » de la tranche de la main. Grâce

à ce point et au point 4, nous conservons une valeur angulaire correspondant à l'angle de référence de la main en position d'initialisation.

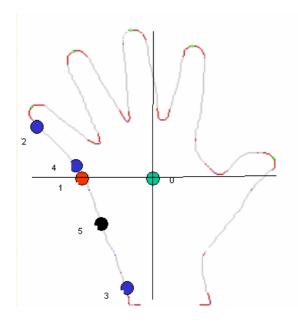


Figure 10. Recherche du « point de bord » de la main, le point numéro 5 sur cette figure Ce point et le point 4 permettent de déterminer l'angle de la main dans le plan face a la camera.

6.4 Recherche du poignet

Du point précédemment trouvé, nous réalisons une projection sur la ligne liant le pouce au poignet. Nous calculons ensuite la distance minimum entre le point de bord et cette ligne. Enfin, de ce point nous cherchons la distance minimum avec la ligne de la tranche de la main, où nous avions précédemment trouvé le point de bord. La localisation de l'articulation du poignet sera estimé au centre des deux minimums.

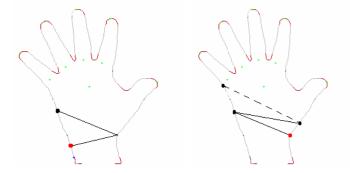


Figure 11. Projections de points de tranche.



Figure 12. Le poignet identifié.

6.5 Mise en place des articulations

Nous cherchons dans une dernière étape la localisation des articulations des phalanges des doigts. Pour ce faire nous utilisons les sommets et les bases des doigts précédemment déterminés, et utilisons des données anthropométriques pour les estimer. Le modèle de suivi présenté dans la dernière partie peut est alors être complètement initialisé. Nous calons donc le modèle de suivi et le modèle 3D avec ces valeurs d'initialisation ; ils se retrouvent alors adaptés à l'utilisateur.

7 Modèle de suivi

Le modèle de suivi est constitué des informations remarquables obtenues précédemment. Il dispose en particulier de 5 doigts, du centre de la main, du poignet et du point de bord. Son évolution temporelle repose sur des recherches localisées, issues des estimations de mouvements globaux des points. Nous suivons le poignet, qui nous offre une matrice de transformation globale à appliquer à tous les points de la main. La méthodologie ici appliquée est de rechercher dans les points de ligne du contour le point le plus proche de l'ancienne position du point de bord. Une fois ce point trouvé, on applique de sa position le principe utilisé aux 5.4 et 5.5 lors de l'initialisation, qui vont nous permettre d'obtenir la nouvelle valeur de position du point de bord, et du poignet. Nous pouvons alors appliquer la transformation globale à la main.

Pour l'heure, seuls les bouts des doigts sont considérés. Nous pouvons alors limiter les recherches à des cadres de taille donnée, dont le centre correspond à la position prévisionnelle calculée précédemment. Dans ces cadres, on calcule alors la valeur exacte de la position des bouts des doigts et on corrige le modèle 3D de la main.

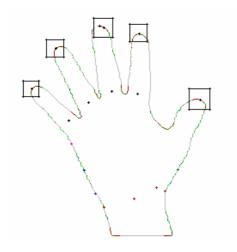
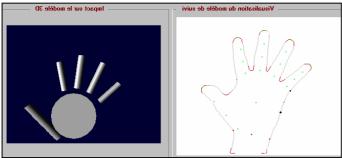


Figure 13. Cadres de recherche des sommets des doigts, pour l'adaptation continue en temps-réel du modèle 3D



. Figure 14. Modèle 3D de la main contrôlé par la main de l'humain

8 Conclusion

Nous avons montré la possibilité de piloter en temps réel une main virtuelle par l'utilisation d'un simple WebCam, le modèle 3D suit les mouvements de la main face à la caméra. L'utilisation qui en a été faite n'a pas été exposée ici mais on peut sans peine imaginer l'utilisation de notre système comme entrée de pilotage d'un robot mobile par exemple. Il nous reste des améliorations à apporter. En particulier, le traitement des problèmes récurrents dans toute opération de suivi de points caractéristiques et les occultations. Ceci nous permettra le passage a des mouvements plus complexes et dans l'espace.

Ce travail a été en partie supporté par la CE dans le cadre du contrat REPOSIT IST-.

9 Références

- R.Gherbi, A.Braffort, Système PoG, groupe [1] **CHM** LIMSI Evry http://www.limsi.fr/RS98FF/CHM98FF/IMM98FF/im m10/
- [2] Hocine Ouhaddi, P.Horain, « Vers la modélisation du geste par la vision », 1999, disponible sur http://www-sim.int-evry.fr/~hand.

- [3] Sébastien Marcel, Olivier Bernier, Daniel Collobert, « Reconnaissance de la main pour les interfaces gestuelles Coresa99, http://sebastien.marcel.free.fr/CVSeb.html .
- [4] W.T.Freeman, « Orientation histograms for recognition », année gesture http://www.merl.com/people/freeman/ori.html.
- [5] Romer Rosales, Vassilis Athitsos, Stan Sclaroff, Technical Report, N° 2000-22, « 3D hand pose reconstruction using specialized mappings » (Specialized Mappings Architectures -Décembre 2000,
- http://citeseer.nj.nec.com/rosales00hand.html.
- [6] Ryad Chellali, Rapport interne INRETS-DART «Comptage de piétons dans le métro Parisien», année 1992.
- [7] Quentin Delamarre, Rapport technique n°0198 « Modélisation de la main pour sa localisation dans une séquence d'images », décembre 1996, http://www.inria.fr/rrrt/rt-0198.html ou http://wwwsop.inria.fr/robotvis/personnel/qdelam/.
- [8] R.Deriche « Contours actifs géodésiques». Support de cours, http://wwwsop.inria.fr/robotvis/personnel/der/deaaravis.html.
- [9] Christos Davatzikos, Jerry L.Prince, Convexity analysis of active contour problems », 1996, http://citeseer.nj.nec.com/43313.html.
- [10] Hocine OUHADDI et Patrick HORAIN, article du 6ème GT-RV, « Conception et ajustement d'un modèle 3D articulé de la main », Mars 1998, http://www-sim.int-evry.fr/~hand.
- [11] Nobutaka SHIMADA et Yoshiaki SHIRAI, « 3D hand pose estimation and shape model refinement from a monocular image sequence », 1996.
- [12] Quentin Delamarre, Olivier Faugeras « Finding pose of hand in video images: a stereo-based 1998, http://wwwapproach sop.inria.fr/robotvis/personnel/qdelam/PUBLI.html .
- [13] Tony Heap, Ferdinando Samaria « Real time hand tracking and gesture recognition using smart Juin 1995, http://citeseer.nj.nec.com/78287.html.
- [14] Tony Heap, David Hogg « Towards 3D hand tracking using a deformable model », http://citeseer.nj.nec.com/52887.html.
- Hocine Ouhaddi, Patrick Horain, Modélisation 3D du geste par la vision », http://wwwsim.int-evry.fr/~hand.
- [16] Renate Kempf et Chris Frazier « OpenGL Programming Guide, 2nd Edition », Adisson-Wesley.
- [17] Nicolas Mollet et Ryad Chellali « Suivi et Modelisation 3D des gestes de la main », Rapport de DEA, Irccyn.